CallMeMaybe · Telecomunicaciones

Análisis de Operadores

Identificación de Operadores Ineficaces

Proyecto Final · Telecomunicaciones

Período de análisis: agosto – noviembre 2019

1,092 operadores · 290 usuarios · 53,902 registros

Resumen Ejecutivo

Este informe presenta el análisis exploratorio de datos, la identificación de operadores ineficaces y las pruebas de hipótesis estadísticas realizadas sobre el dataset de CallMeMaybe (agosto – noviembre 2019). Se analizaron **1,092 operadores** de **290 clientes** con un total de **53,902 registros**.

53,902	**1,092**	**290**	**273**
Registros totales	Operadores	Usuarios/clientes	Operadores ineficaces
43.72%	**165s**	**34s**	**13.48%**
Llamadas perdidas	Duración mediana	Espera mediana	Llamadas internas

1. Análisis Exploratorio de Datos (EDA)

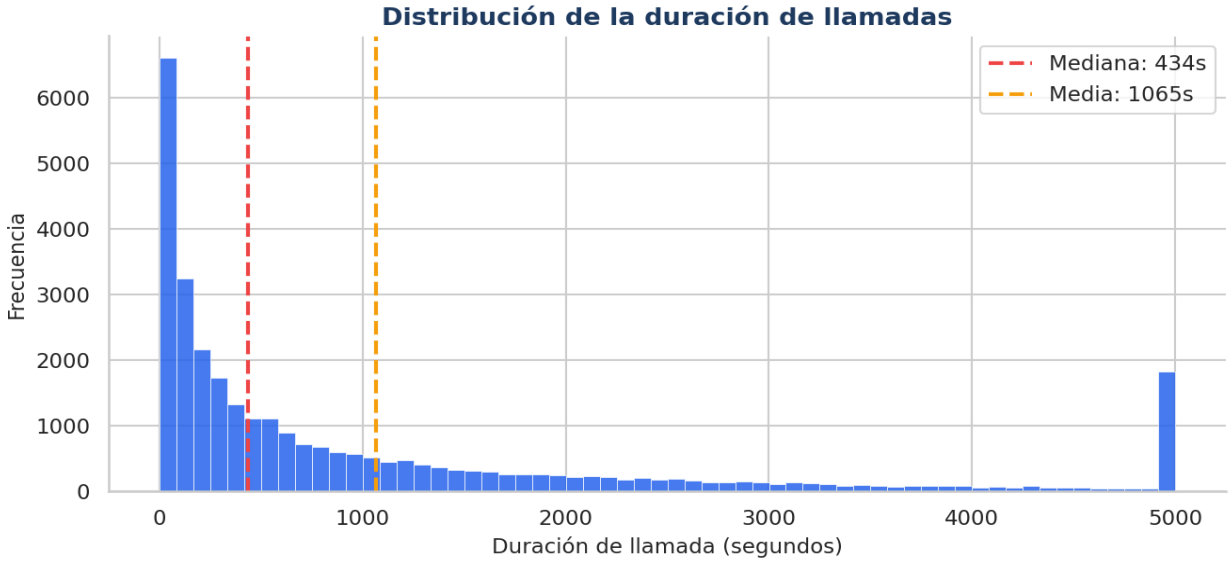
1.1 Descripción del dataset

El dataset principal contiene 53,902 registros correspondientes al período **agosto–noviembre de 2019**. Se observó que **8,172 registros (15.2%)** no tienen operador asignado, correspondiendo a llamadas del sistema o registros de enrutamiento; estos fueron excluidos del análisis por operador. El dataset de clientes cuenta con **732 registros** y **3 planes tarifarios** (A, B, C).

Hallazgos clave del EDA:

- **Dirección:** El 59.1% de las llamadas son salientes (*out*) y el 40.9% entrantes (*in*).
- **Llamadas perdidas:** El 43.7% del total son llamadas perdidas, una cifra muy elevada que justifica el análisis de ineficiencia.
- **Llamadas internas:** Representan el 13.5% del total; el 86.5% son externas.
- **Duración mediana:** 165 segundos (~2.7 min) para llamadas con duración > 0.
- **Tiempo de espera mediano (entrantes):** 34 segundos; la media es 290s, indicando distribución sesgada con casos extremos.
- **Valores atípicos:** Se identificaron tiempos de espera superiores a 46,000 segundos (~12.9 horas), probablemente llamadas en cola abandonadas.

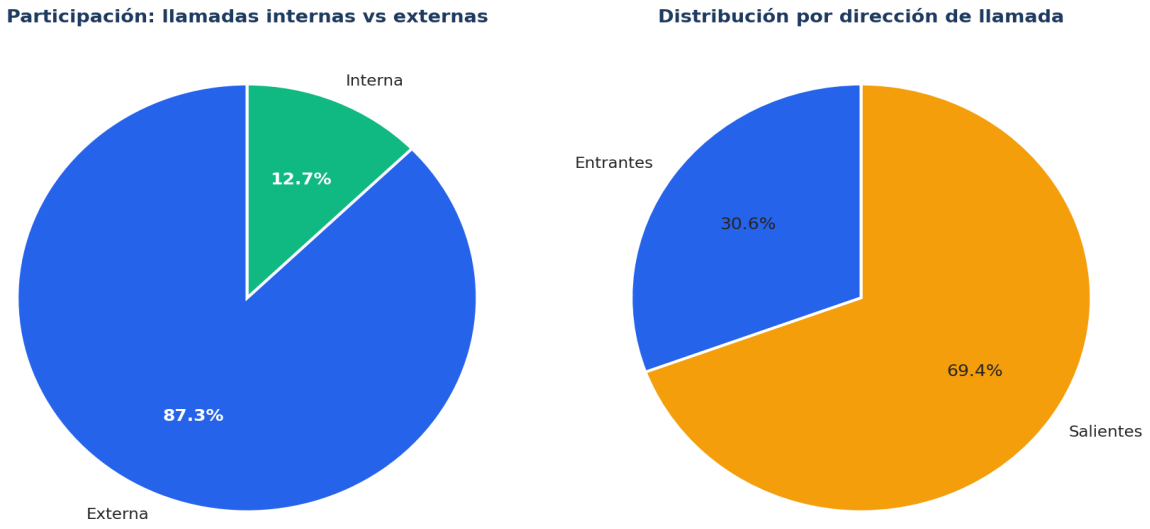
Distribución de la duración de llamadas



La distribución es fuertemente asimétrica a la derecha (sesgada positivamente). La mayoría de las llamadas tienen duración corta, pero existe una cola larga con llamadas de hasta 144,000 segundos (~40 horas). La mediana (165s) es mucho menor que la media (867s), confirmando el efecto de los valores atípicos.

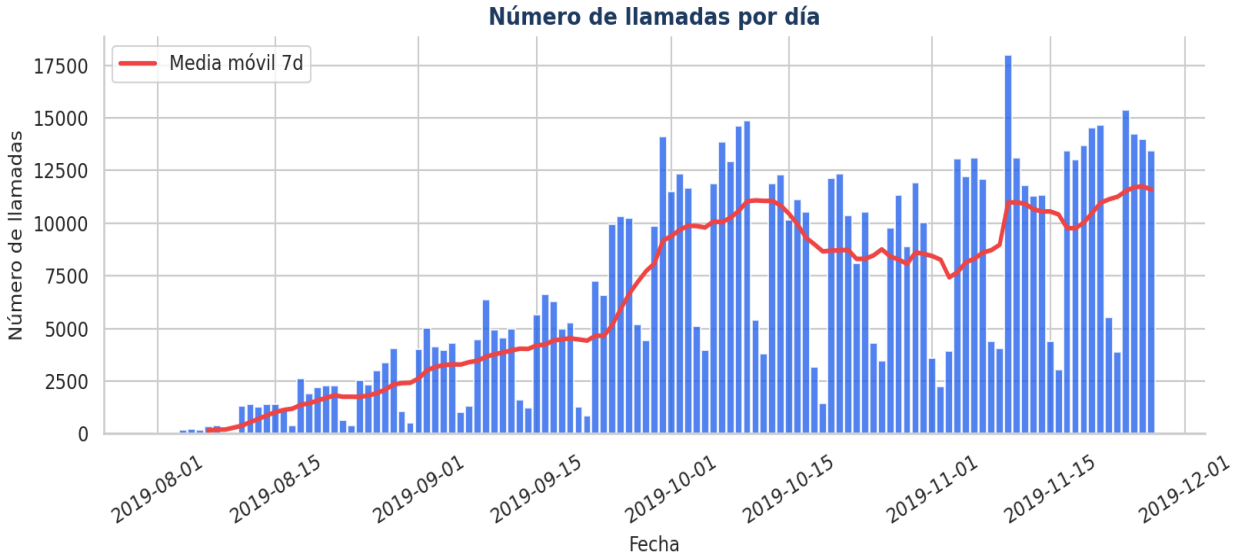
1. Análisis Exploratorio de Datos (EDA) — cont.

1.2 Composición de llamadas



El 86.5% de las llamadas son externas, lo que es típico de centros de llamadas con actividad comercial intensa. La distribución saliente/entrante (59%/41%) indica mayor volumen de llamadas de outbound, posiblemente campañas activas.

1.3 Evolución temporal del volumen de llamadas



El volumen diario de llamadas muestra picos notables en septiembre–octubre 2019. La media móvil de 7 días revela tendencia relativamente estable con algunas semanas de alta actividad. Se observan caídas los fines de semana, consistente con operaciones B2B.

2. Metodología: Identificación de Operadores Ineficaces

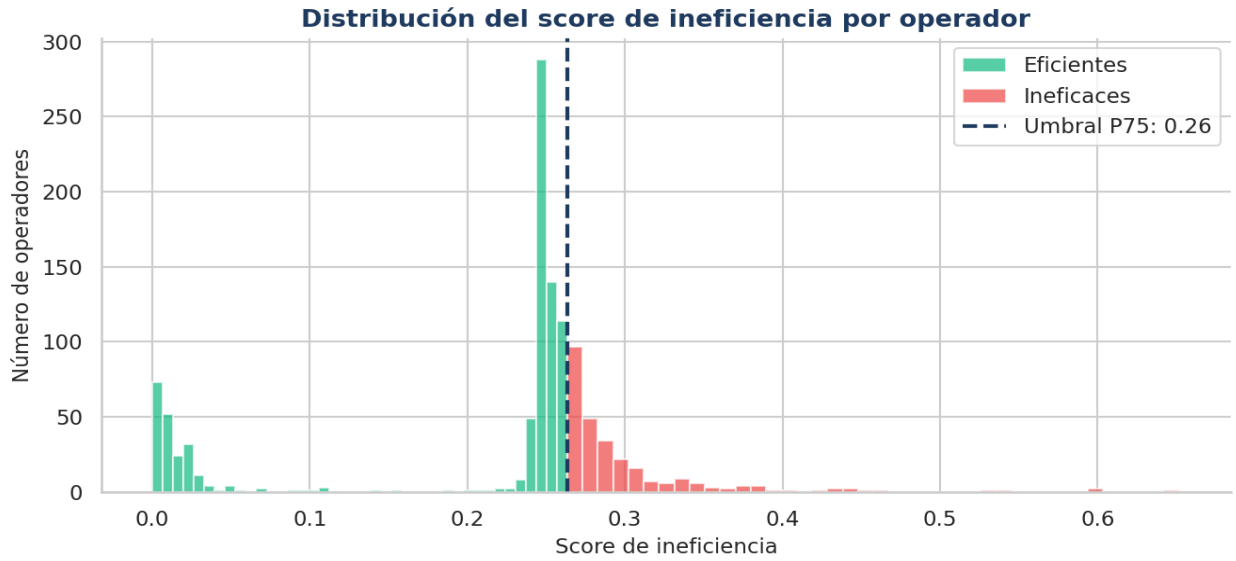
Para identificar operadores ineficaces se construyó un **score compuesto de ineficiencia** basado en las tres dimensiones definidas por el negocio:

#	Dimensión	Métrica	Peso	Interpretación
1	Llamadas perdidas entrantes	Tasa de llamadas perdidas (entrantes / total entrantes)	40%	Alto → más ineficaz
2	Tiempo de espera entrante	Promedio de tiempo de espera en llamadas entrantes (segundos)	35%	Alto → más ineficaz
3	Llamadas salientes (si aplica)	Total de llamadas salientes realizadas	25%	Bajo → más ineficaz

Proceso de cálculo del score:

- **Paso 1:** Calcular las tres métricas por operador a partir de los registros agrupados.
- **Paso 2:** Normalizar cada métrica al rango [0, 1] con Min-Max Scaling para que sean comparables.
- **Paso 3:** Para salientes, invertir la escala (1 – valor normalizado) ya que más llamadas = más eficiente.
- **Paso 4:** Calcular el score ponderado: 0.40 × missed + 0.35 × wait + 0.25 × out_inv.
- **Paso 5:** Clasificar como **ineficaz** a los operadores con score ≥ percentil 75 (umbral = 0.263).

2.1 Distribución del score de ineficiencia



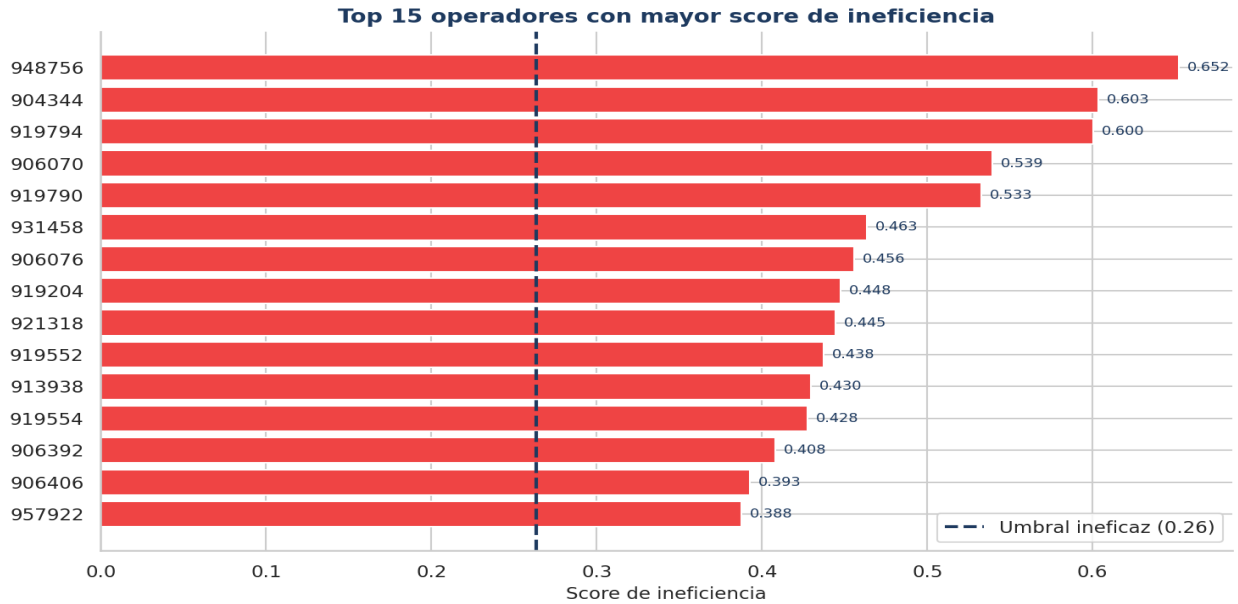
*Se identificaron **273 operadores ineficaces** (25% superior) y **819 operadores eficaces**. La distribución muestra separación clara entre ambos grupos a partir del umbral.*

2. Resultados: Operadores Ineficaces — cont.

2.2 Top 10 operadores más ineficaces

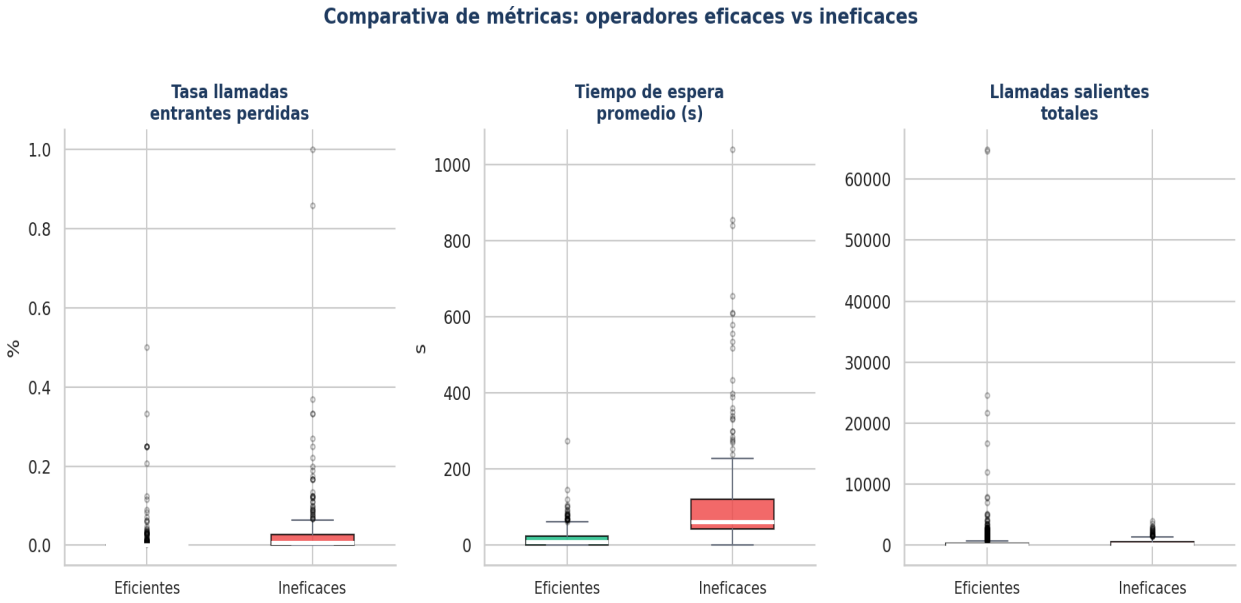
Rank	Operador ID	% Perdidas entrantes	T. Espera prom. (s)	Llamadas salientes	Score
1	948756	100.0%	8	175	0.652
2	904344	85.7%	31	5	0.603
3	919794	0.1%	1040	21	0.600
4	906070	0.6%	853	89	0.539
5	919790	0.0%	840	25	0.533
6	931458	0.7%	655	2,561	0.463
7	906076	0.0%	612	1	0.456
8	919204	0.7%	579	9	0.448
9	921318	0.3%	607	2,864	0.445
10	919552	0.1%	557	70	0.438

Los 3 operadores con mayor score (fondo rojo) presentan patrones críticos: el operador 948756 pierde el 100% de sus llamadas entrantes; 919794 y 906070 tienen tiempos de espera superiores a 850 segundos (~14 minutos).



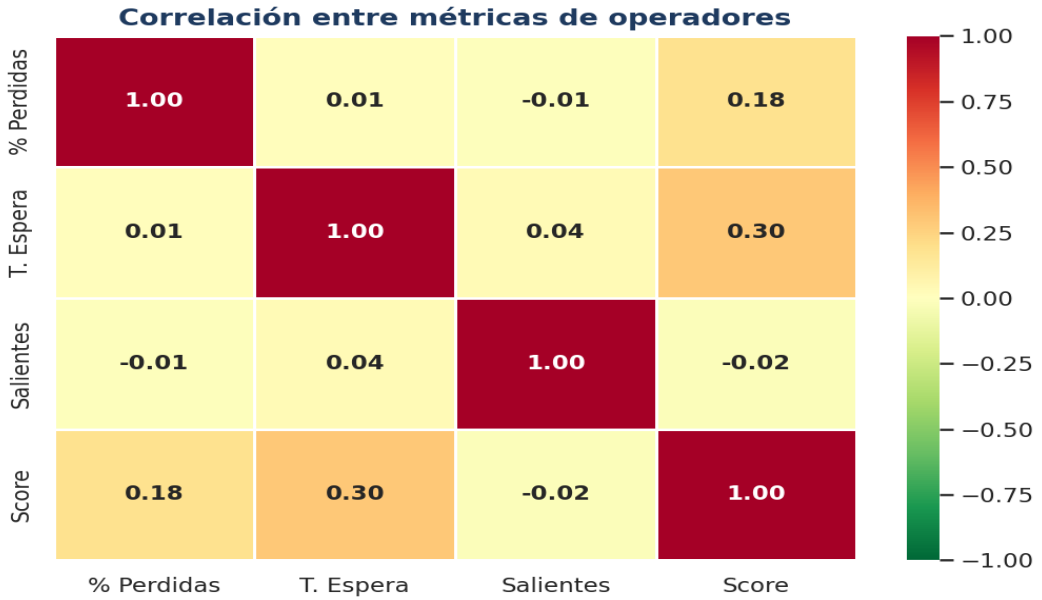
2. Resultados: Comparativa Eficaces vs Ineficaces

2.3 Comparativa de métricas por grupo



Los diagramas de caja muestran diferencias sustanciales entre grupos. Los operadores ineficaces tienen medianas de tasa de pérdida y tiempo de espera significativamente más altas. En llamadas salientes, la distribución es más amplia en ambos grupos, lo que dificulta la separación solo por esta métrica.

2.4 Correlación entre métricas



El mapa de calor revela que la tasa de llamadas perdidas y el tiempo de espera tienen correlación positiva moderada con el score de ineficiencia. Las llamadas salientes muestran correlación débil, lo que es consistente con que no todos los operadores tienen asignadas llamadas outbound.

3. Pruebas de Hipótesis Estadísticas

Se utilizó la **prueba de Mann-Whitney U** (no paramétrica) dado que las distribuciones de las métricas no siguen una distribución normal (confirmado visualmente y por la asimetría de los datos). Se usó un nivel de significancia α **= 0.05**.

Hipótesis H1	✓ SE RECHAZA H■
Tasa de llamadas perdidas: ineficaces > eficaces	U = 178,138.5 p = 4.15e-92

Hipótesis H2	✓ SE RECHAZA H■
Tiempo de espera entrante: ineficaces > eficaces	U = 206,333.5 p = 1.14e-100

Hipótesis H3	✗ NO SE RECHAZA H■
Llamadas salientes: eficaces > ineficaces	U = 71,906.5 p = 9.99e-01

Interpretación de resultados:

H1 (p ≈ 0): Existe evidencia estadística muy sólida de que los operadores ineficaces tienen una tasa de llamadas perdidas significativamente mayor. Este es el indicador más discriminador.

H2 (p ≈ 0): Los operadores ineficaces presentan tiempos de espera entrante significativamente más altos. Esta métrica también es altamente predictiva.

H3 (p = 0.999): No se encontró evidencia de que los operadores eficaces realizan más llamadas salientes que los ineficaces. Esto puede deberse a que muchos operadores ineficaces también tienen altos volúmenes de salientes, y que la cantidad de salientes per se no refleja eficiencia sin considerar la tasa de éxito.

4. Conclusiones y Recomendaciones

4.1 Conclusiones principales

• Se identificaron **273 operadores ineficaces** (25% del total de 1,092) usando un score compuesto que pondera tasa de llamadas perdidas, tiempo de espera y volumen de salientes.

• La **tasa de llamadas perdidas entrantes** es el indicador más poderoso de ineficiencia, con diferencias estadísticamente significativas entre grupos ($p \approx 0$).

• El **tiempo de espera promedio** es el segundo indicador más discriminante ($p \approx 0$). Algunos operadores presentan esperas medianas superiores a 600 segundos.

• El **volumen de llamadas salientes** por sí solo no distingue operadores eficaces de ineficaces ($p = 0.999$). Sería más informativo usar la tasa de éxito de salientes.

• Los **3 operadores más críticos** (948756, 904344, 919794) requieren intervención inmediata: presentan tasas de pérdida superiores al 75% o tiempos de espera extremos.

• El **43.7% de llamadas perdidas** a nivel global sugiere problemas sistémicos más allá de operadores individuales: posible sub-dimensionamiento de plantilla o enrutamiento deficiente.

4.2 Recomendaciones

• **Priorizar revisión** de los 20 operadores con score > 0.35 con sus supervisores.

• **Incorporar tasa de éxito** de llamadas salientes como métrica complementaria.

• **Revisar el enrutamiento** de llamadas para operadores con tiempos de espera >600s.

• **Establecer umbrales de alerta** automáticos: tasa de pérdida >30% o espera >120s.

• **Analizar patrones temporales** por operador para detectar ineficiencia estacional.

• **Ampliar el período** de análisis para validar si los operadores ineficaces son consistentemente problemáticos o si se trata de eventos puntuales.

5. Fuentes y Referencias

1. Pandas Documentation	*https://pandas.pydata.org/docs/*
Manipulación y agrupación de datos: groupby, merge, agg. Respondió cómo calcular métricas por operador de forma eficiente.	
2. SciPy Stats — Mann-Whitney U	*https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.mannwhitneyu.html*
Implementación de la prueba no paramétrica para comparar distribuciones sin asumir normalidad. Clave para las 3 hipótesis estadísticas.	
3. Scikit-learn — MinMaxScaler	*https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html*
Normalización de métricas heterogéneas al rango [0,1] para construir el score compuesto de ineficiencia.	
4. Seaborn Documentation	*https://seaborn.pydata.org/*
Visualizaciones estadísticas: boxplots comparativos entre grupos (eficaces vs ineficaces) y mapas de calor de correlaciones.	
5. Matplotlib Documentation	*https://matplotlib.org/stable/contents.html*
Histogramas de distribución, gráficos de barras horizontales (top operadores ineficaces) y series temporales de volumen diario.	
6. ReportLab User Guide	*https://www.reportlab.com/docs/reportlab-userguide.pdf*
Generación del informe en PDF: tablas, estilos, imágenes embebidas y numeración de páginas con canvas personalizado.	
7. Towards Data Science — Building KPI Scorecards	*https://towardsdatascience.com/*
Marco conceptual para construir scores compuestos con pesos, normalización y umbrales percentílicos en contextos operacionales.	
8. Statistics How To — Mann-Whitney U Test	*https://www.statisticshowto.com/mann-whitney-u-test/*
Guía sobre cuándo usar pruebas no paramétricas vs paramétricas y cómo interpretar el valor U y el p-value.	
9. Yandex Practicum — Telecomunicaciones	*https://practicum.yandex.com/*
Contexto del proyecto, descripción de los datasets y criterios de negocio para definir qué es un operador ineficaz en CallMeMaybe.	

10. NumPy Documentation	*https://numpy.org/doc/*
Operaciones de percentil (np.quantile) para fijar el umbral del score y manejo de valores nulos en métricas por operador.	